

HW05 Task 3 — Đề xuất Continuous Performance Testing (G9.6)


1. Mô hình đề xuất


Không chạy performance test trên mọi commit — chi phí một lần chạy Spike đầy đủ ở quy mô của bài này đã là hơn 300s và gần 470k mẫu (`reports/run-manifest.md`). Mô hình đề xuất là một pipeline theo dõi commit của SUT (`eshop-sut`), phân loại commit đó bằng đường dẫn file thay đổi, quyết định có cần chạy hay không và chạy kịch bản nào, rồi so kết quả với baseline theo từng label — tái dùng nguyên vẹn hạ tầng đã có ở bài này thay vì dựng công cụ mới:

- **Test plan:** chính 4 file `.jmx` đã chấm điểm (`perf/plans/jmeter/23127300_{Load,Stress,Spike,Endurance}_20260814.jmx`) — không nhân bản, không viết lại cho CI.
- **Dữ liệu:** cùng `perf/data/accounts.csv` / `products.csv` , tái tạo bằng `perf/scripts/seed-accounts.sh` mỗi lần chạy để không cạn dữ liệu qua nhiều lần CI (đúng nguyên tắc data-driven §6 và bài học "mỗi VU một hàng riêng" đã áp dụng ở Task 1).
- **Bộ thực thi:** `perf/scripts/run-scenario.sh <Scenario> [--fresh]` — script này đã tự reset lockout trước khi chạy và ghi `.jtl/HTML dashboard/resource trace` cùng một stem, nên CI chỉ cần gọi đúng lệnh đã dùng thủ công ở Task 1.
- **Bộ so sánh:** `perf/scripts/analyze_jtl.py --json --skip-ramp N` — đã có sẵn chế độ output máy đọc được (`--json`) và chế độ bỏ ramp-up, đúng hai thứ một job CI cần để so p95 theo từng label mà không phải viết lại logic phân tích.

Không có thành phần nào trong mô hình là công cụ mới; nó là cách lắp lại đúng 4 mảnh đã kiểm chứng ở Task 1/2 thành một vòng lặp tự động.

2. Lưu đồ





3. Tiêu chí quyết định chạy test

Tín hiệu từ commit	Hành động	Lý do
Sửa route/handler hoặc câu truy vấn ở backend	Chạy full (Load + Stress + Spike)	Đây chính là tầng mà 3 kịch bản của HW05 đo — thay đổi ở đây có khả năng cao nhất làm dịch p95 hoặc error % theo từng label.
Đổi dependency lockfile (package-lock.json hoặc tương đương)	Chạy full	Nâng cấp một thư viện (driver DB, HTTP framework...) có thể đổi hành vi hiệu năng mà không đổi một dòng code nghiệp vụ nào — diff code sẽ trống nhưng rủi ro hiệu năng thì không.
Chỉ sửa frontend hoặc tài liệu (docs/ , README , *.md)	Bỏ qua (skip)	Không chạm tới bất kỳ endpoint nào trong 7 sampler của Workflow 5; chạy vẫn tốn tài nguyên runner mà không sinh tín hiệu mới.
PR gắn nhãn perf:full	Ép chạy full, bất kể phân loại đường dẫn	Van thoát cho người review — một thay đổi "nhìn có vẻ an toàn" theo đường dẫn vẫn có thể cần đo nếu người viết PR nghi ngờ tác động hiệu năng.
Lịch nightly	Luôn chạy full + Endurance	Đây là chỗ duy nhất chạy Endurance (15 phút) — quá tốn để chạy theo từng PR, nhưng cần chạy đều đặn để bắt trôi dạt chậm (rò rỉ bộ nhớ) mà một lần chạy PR ngắn không thấy được, đúng như mục 2.7 của báo cáo chính đã đo.
Commit revert	Chạy full	Xác nhận việc revert thật sự đưa hệ thống về lại đúng baseline hiệu năng trước đó, không chỉ về lại đúng code — một revert sai vị trí (revert nhầm phần không liên quan) vẫn có thể để lại tác động hiệu năng.

4. Phát hiện hồi quy p95

- **Baseline:** median trượt của N=7 lần chạy xanh gần nhất, cùng runner class (không trộn số từ máy khác cấu hình khác). Chọn 7 chứ không phải 1 vì chính bộ dữ liệu HW05 đã cho thấy một lần chạy đơn lẻ dao động do phần cứng dùng chung: 07 POST /api/checkout p95 đi từ 7ms đến 9ms xuyên suốt sweep calibration 25–300 luồng dù không có gì thay đổi ở SUT (perf/results/calibration/calibration-20260814.md , bảng "Knee sweep") — lấy 1 lần chạy làm baseline sẽ khoá vào đúng lúc dao động đó. Median của 7 lần đủ để lọc dao động đơn lẻ mà vẫn phản ứng trong vòng một tuần làm việc bình thường.
- **So sánh theo từng label, không theo tổng hợp:** đúng bài học rút ra ở Task 2 (reports/ai-analysis-review.md mục 2.2) — p95 gộp cả 7 sampler che mất việc một label cụ thể (ví dụ checkout) trượt trong khi các label khác kéo trung bình xuống. So sánh phải chạy trên chính output theo-label của analyze_jtl.py , không phải dòng ALL .
- **Ngưỡng báo động:** vượt baseline 40% và vượt một sàn tuyệt đối +3ms, cả hai điều kiện cùng đúng mới báo. Lý do cần cả hai: các sampler đọc (04 , 05) và transactional (06) ở p95 dưới 10ms trong cả 4 lần chạy đã chấm điểm (reports/run-manifest.md) — với độ trễ nhỏ cỡ này, một dao động 2ms do phần cứng dùng chung (như bảng knee-sweep ở trên) đã là 20–30% tương đối, đủ để

một ngưỡng phần trăm thuần túy báo động giả liên tục; sàn tuyệt đối +3ms lọc bỏ đúng loại nhiễu đó. Ngược lại, với label chậm như `01 POST /api/forgot-password` ở Spike (p95 152ms), sàn tuyệt đối 3ms gần như luôn bị vượt — phần trăm 40% mới là điều kiện có ý nghĩa ở quy mô đó.

- **Hai lần vi phạm liên tiếp mới fail build:** một lần vi phạm chạy lại ngay (RETRY trong lưu đồ); chỉ khi lần chạy lại vẫn vi phạm đúng label đó mới fail. Cơ sở: chính bộ khung đo của bài này chạy JMeter và SUT **chung 12 lõi** (`perf/results/calibration/calibration-20260814.md` mục "Hardware and harness") — một CI runner dùng chung tài nguyên với job khác cũng sẽ có kiểu nhiễu tương tự, và yêu cầu lặp lại trước khi fail là cách rẻ nhất để phân biệt nhiễu runner một lần khỏi hồi quy thật.

5. Đánh đổi

Đánh đổi	Thảo luận
Chi phí	Full (Load+Stress+Spike) tốn khoảng 22 phút wall-clock theo đúng thời lượng đã đo ở 4 lần chạy chấm điểm (362s+607s+306s ≈ 21 phút, chưa kể Endurance 903s nếu chạy nightly) — không rẻ để chạy trên mọi PR, đây là lý do bảng phân loại ở mục 3 chỉ chạy full khi tín hiệu commit thật sự đáng ngờ, và để Load-only (ngắn hơn nhiều, 362s) làm mặc định cho các PR "an toàn" theo phân loại nhưng vẫn chạm backend.
Báo động giả	Ngưỡng hai điều kiện (phần trăm + sàn tuyệt đối) và yêu cầu 2 lần vi phạm liên tiếp (mục 4) trực tiếp nhắm vào loại nhiễu mà chính calibration của bài này đã đo được (dao động p95 2ms trên sampler dưới 10ms, JMeter và SUT tranh chấp cùng 12 lõi) — không phải suy đoán, mà lấy thẳng biên độ nhiễu đã quan sát làm cơ sở đặt ngưỡng.
Độ trễ phản hồi cho dev	Load-only trên PR thường (362s ≈ 6 phút) đủ nhanh để nằm trong vòng lặp review bình thường; full chỉ kích hoạt khi phân loại đường dẫn hoặc nhận <code>perf:full</code> báo hiệu rủi ro cao hơn, nên phần lớn PR không phải chờ 22 phút. Cái giá phải trả: một PR đổi route backend nhưng bị phân loại nhầm là "an toàn" sẽ không có full run cho tới nightly — độ trễ phát hiện tối đa là một ngày thay vì một PR.
Nhiều do phần cứng runner	Cùng một máy 12 lõi dùng cho cả HW05 đã cho thấy JMeter tự tốn tới 168.6% CPU ở 300 luồng và cạnh tranh trực tiếp với SUT (<code>perf/results/calibration/calibration-20260814.md</code>) — một CI runner chia sẻ (đặc biệt là runner ảo hoá dùng chung với job khác) sẽ nhiều hơn máy cá nhân này, không kém đi. Cơ chế quarantine ở lưu đồ (một label liên tục báo động qua nhiều commit không liên quan) là van an toàn cho đúng trường hợp này: chuyển label đó sang chỉ-cảnh-báo thay vì chặn build, và đánh dấu cần xem lại runner class thay vì code.